

O artigo “*Model Context Protocol (MCP): Landscape, Security Threats, and Future Research Directions*” apresenta o Model Context Protocol (MCP), um padrão emergente que visa padronizar a comunicação entre modelos de inteligência artificial (IA) e ferramentas externas, como APIs, bancos de dados e serviços web. O principal objetivo do MCP é reduzir a fragmentação existente nas integrações atuais, promovendo interoperabilidade, escalabilidade e maior eficiência no desenvolvimento de aplicações baseadas em IA.

Nos últimos anos, o avanço dos modelos de linguagem e agentes autônomos impulsionou a necessidade de integração com sistemas externos. Antes do MCP, essas integrações eram realizadas por meio de conexões manuais com APIs, plugins específicos ou frameworks de agentes. Essas abordagens, embora funcionais, apresentavam limitações significativas, como alto custo de manutenção, dependência de plataformas específicas e dificuldade de escalabilidade. O MCP surge como uma solução para esses problemas ao oferecer um protocolo padronizado, capaz de unificar a forma como ferramentas são descobertas, descritas e utilizadas por sistemas de IA.

A arquitetura do MCP é composta por três componentes principais: o **MCP Host**, o **MCP Client** e o **MCP Server**. O host é a aplicação de IA que executa tarefas e interage com o usuário. O client atua como intermediário, sendo responsável por enviar requisições, receber respostas e gerenciar a comunicação. Já o server é responsável por disponibilizar ferramentas, recursos e prompts que permitem a interação com sistemas externos. Essa estrutura possibilita uma comunicação bidirecional, na qual não apenas o modelo solicita ações, mas também recebe notificações e eventos em tempo real.

O funcionamento do MCP baseia-se em um fluxo estruturado. Inicialmente, o usuário envia uma solicitação ao sistema. Em seguida, o client analisa a intenção da requisição e consulta o server para identificar quais ferramentas estão disponíveis. Após a seleção da ferramenta adequada, o server executa a ação necessária (como acessar uma API ou banco de dados) e retorna o resultado ao client, que o encaminha ao usuário. Esse processo permite que aplicações de IA realizem tarefas complexas de forma automatizada e eficiente.

Outro ponto importante abordado no artigo é o ciclo de vida do servidor MCP, dividido em quatro fases: criação, implantação, operação e manutenção. Na fase de criação, o desenvolvedor define as funcionalidades, metadados e capacidades do servidor. Na implantação, o servidor é disponibilizado para uso e integrado a ambientes de execução. Durante a operação, ocorre a interação com usuários e sistemas externos. Já na fase de

manutenção, são realizadas atualizações, auditorias e melhorias contínuas. Esse modelo estruturado contribui para a organização e segurança do ecossistema.

O artigo também analisa o crescimento do ecossistema MCP, destacando sua adoção por diversas empresas e plataformas tecnológicas. Grandes organizações têm incorporado o protocolo para melhorar a integração entre sistemas de IA e ferramentas externas, especialmente em ambientes de desenvolvimento, computação em nuvem e automação de processos. Essa adoção demonstra o potencial do MCP como base para a construção de aplicações mais flexíveis e inteligentes.

Apesar das vantagens, o trabalho enfatiza que o MCP ainda apresenta desafios significativos, especialmente no que diz respeito à segurança. Os autores propõem uma taxonomia de ameaças que classifica os riscos em quatro categorias principais: desenvolvedores maliciosos, atacantes externos, usuários mal-intencionados e falhas de segurança. Entre os principais problemas identificados estão ataques como falsificação de servidores (typosquatting), manipulação de preferências, envenenamento de ferramentas, execução de comandos maliciosos e vazamento de dados sensíveis.

Essas ameaças são particularmente preocupantes porque o MCP depende fortemente de metadados e descrições textuais para a seleção de ferramentas. Isso abre espaço para manipulação, onde agentes maliciosos podem influenciar o comportamento do sistema sem alterar diretamente o código. Além disso, a natureza distribuída e dinâmica do MCP aumenta a superfície de ataque, tornando essencial a implementação de mecanismos robustos de segurança, como autenticação, verificação de integridade e auditoria de atividades.

Para mitigar esses riscos, o artigo propõe diversas medidas de segurança, incluindo validação de metadados, uso de assinaturas criptográficas, monitoramento de comportamento e controle rigoroso de permissões. Também destaca a importância de práticas como versionamento, auditoria de logs e isolamento de ambientes para garantir a confiabilidade do sistema.

Por fim, os autores discutem as perspectivas futuras do MCP, ressaltando a necessidade de avanços em áreas como padronização, governança, escalabilidade e segurança. O protocolo tem potencial para se tornar um componente fundamental na evolução das aplicações de IA, especialmente em cenários que exigem integração com múltiplos sistemas e execução de tarefas complexas. No entanto, seu sucesso dependerá da capacidade da comunidade tecnológica de enfrentar os desafios identificados e promover um ecossistema seguro, confiável e sustentável.

Em síntese, o MCP representa um avanço significativo na forma como sistemas de inteligência artificial interagem com o mundo externo. Ao oferecer uma abordagem padronizada e flexível, ele possibilita a criação de aplicações mais poderosas e integradas. Contudo, sua adoção em larga escala exige atenção especial à segurança e à governança, garantindo que seus benefícios sejam aproveitados de forma responsável e eficiente.